الهدف الأساسي من NLP هو:(ب)
أ) تحليل الصور
ب) فهم اللغة البشري
ج) تحسين الشبكات
د) ضغط البيانات
Tokenization تعني:(ب)
أ) ترجمة النص
ب) تقسيم النص
ج) ضغط النص
د) حذف الكلمات
Stop Words هي:(ب)
أ) كلمات نادرة
ب) كلمات شائعة قليلة القيمة
ج) كلمات تقنية
د) كلمات طويلة
TF-IDF يستخدم لـ:(ب)
أ) الترجمة
ب) تمثيل النص
ج) تصنيف الصور
د) ضغط البيانات
Bag of Words:(ب)
أ) يحافظ على ترتيب الكلمات
ب) يهمل الترتيب
ج) يستخدم الشبكات العصبية
د) يعتمد على السياق
أي نموذج يعتمد على السياق؟(ج)
أ) TF-IDF
ب) Bag of Words
ج) BERT
د) Count Vector
Lemmatization:(ب)
أ) تقطيع النص
ب) تحويل الكلمة لأصلها
ج) حذف الكلمات
د) ضغط النص
Word2Vec ينتج:(ب)
أ) صور
ب) متجهات
ج) جمل
د) قواعد
أي خوارزمية مناسبة لتصنيف النص؟(ب)
أ) KNN
ب) Naive Bayes
ج) Decision Tree
د) جميع ما سبق
NER تعني:(ب)
أ) تحليل المشاعر
ب) التعرف على الكيانات
ج) الترجمة
د) تصنيف النص
Overfitting يعني:
أ) نموذج ضعيف
ب) نموذج يحفظ البيانات

ج) نموذج سريع
د) نموذج بسيط
Underfitting يعني:(أ)
أ) نموذج بسيط جدًا
ب) نموذج معقد
ج) نموذج دقيق
د) نموذج سريع
Embedding هو:(ب)
أ) صورة
ب) تمثيل رقمي للكلمات
ج) نص
د) خوارزمية
Language Model هدفه:(ب)
أ) الترجمة
ب) توقع الكلمة التالية
ج) ضغط النص
د) حذف الكلمات
Transformer يعتمد على:(ج)
أ) CNN
ب) RNN
ج) Attention
د) KNN
Attention يساعد في:(ب)
أ) حذف الكلمات
ب) التركيز على الكلمات المهمة
ج) ضغط النص
د) تحويل النص
POS Tagging:(ب)
أ) ترجمة
ب) تحديد نوع الكلمة
ج) حذف الكلمات
د) تحليل الصور
أي مما يلي Unsupervised؟(ب)
أ) Classification
ب) Clustering
ج) Regression
د) Decision Tree
Cosine Similarity تستخدم لـ:(ب)
أ) الترجمة
ب) قياس التشابه
ج) تصنيف الصور
د) ضغط النص
GPT هو:(أ)
أ) نموذج لغة
ب) خوارزمية تصنيف
ج) قاعدة بيانات
د) نظام تشغيل

✍ القسم الثاني: أسئلة نظرية (15 سؤال)
اشرح مفهوم Tokenization مع مثال: هي عملية تقسيم الجملة إلى أجزاء وكلمات منفصلة للتعامل معها. مثال: الجملة "We're moving to L.A." تُقسم إلى "We", "'re", "moving", "to", "L.A", ".", "!" بناءً على الفراغات والرموز والمعنى

ما الفرق بين Stemming و Lemmatization؟ كلاهما يهدف لتجريد الكلمة من الإضافات والعودة لمصدرها.
تقنية Lemmatization أكثر قوة لأنها تبحث في المعنى والأساس (مثل إرجاع was إلى be) وتراعي سياق الجملة،

بينما Stemming تكتفي بحذف الحروف الزائدة وقد تنتج كلمات غير دقيقة

ما هو Bag of Words؟ وما عيوبه؟ هي طريقة لمعرفة مدى تواجد كل كلمة في النص وتكرارها دون الاعتماد على ترتيبها. من عيوبها عدم التركيز على معاني الكلمات والبطء الكبير في العملية

اشرح TF-IDF وكيف يعمل. تقنية تجمع بين تكرار الكلمة في المستند (TF) واللوغاريتم العكسي لعدد المستندات التي ظهرت فيها (IDF). تعمل على إعطاء وزن أكبر للكلمات النادرة ذات التأثير القوي، ووزن أقل للكلمات الشائعة جداً

ما هي Word Embeddings؟ مصفوفة تمثل كل كلمة بقيم رقمية (Vectors) لتحديد معناها ومعرفة مدى تقاربها أو ابتعادها عن الكلمات الأخرى

الفرق بين Word2Vec و GloVe: أداة Word2Vec هي شبكة عصبية من طبقتين تعتمد على السياق لاستنتاج الكلمات (عبر CBOW أو Skip-Gram) ، بينما GloVe يعتمد على تضمين الكلمات والمكتبات سابقة التدريب.

ماهي التحديات في اللغة العربية: الاختلاف الكبير في اللهجات، الاستخدامات المجازية، واللغة غير الرسمية ، بالإضافة إلى الضعف في أداء بعض المكتبات الجاهزة (مثل NLTK و Spacy) مع النصوص العربية.

مفهوم Language Modeling: أسلوب يتعامل مع عدد معين من الكلمات السابقة لاستنتاج وتوقع الكلمة الجديدة.

ما هو Attention Mechanism و الفرق بين RNN و Transformer؟ (مفاهيم تعتمد على التركيز على أجزاء محددة من النص بدلاً من معالجته تسلسلياً كما في RNN، ذُكرت كأسماء تقنيات حديثة في الفهرس

).ما هو NER مع مثال؟ التعرف على الكيانات المسماة وتصنيفها كأشخاص، ومؤسسات، ودول. مثال: استخراج كلمة Apple وتصنيفها كمنظمة (ORG)، واستخراج $6 million وتصنيفها كمبلغ مالي.

اشرح POS Tagging: تحديد نوع الكلمة نحوياً (مثل فعل، اسم، صفة) بناءً على سياقها وموضعها في الجملة.

ما هو Sentiment Analysis؟ تحليل المشاعر لتقييم التعليقات واستخلاص الانطباعات، سواء كانت إيجابية أو سلبية.

Supervised vs Unsupervised في NLP: التعليم بدون إشراف (Unsupervised) يستخدم لتصنيف الكلمات لعناقيد بناءً على معانيها الدفينة (مثل LDA). بينما الإشراف (Supervised) يعتمد على تدريب النموذج على أمثلة وتصنيفات محددة مسبقاً لحساب احتمالاتها

القسم الثالث: أسئلة عملية وتحليلية (15 سؤال)

قم بعمل Tokenization للجملة: "الذكاء الاصطناعي يغير العالم"
["الذكاء", "الاصطناعي", "يغير", "العالم"]

احذف Stop Words من الجملة "أنا أريد أن أتعلم معالجة اللغات الطبيعية"
ستُحذف كلمتي "أنا" و "أن" (بناءً على قوائم التوقف العربية) لتصبح: ["أريد"، "أتعلم"، "معالجة"، "اللغات"، "الطبيعية"]

إذا ظهرت كلمة في 50 مستند من أصل 1000:
احسب IDF تقريبياً
القانون = log10(n/df)
log10(1000/50)=log10(20)
بما انlog10(10)=1وlog10(100)
فان القيمة التقريبية =1.3

احسب Cosine Similarity بين متجهين بسيطين (أعطِ مثال).

A = [1 ,0 ,1]
B = [1 ,1 ,1]
الناتج

Cosine Similarity= 0.82

لديك بيانات نصية:
كيف تحوّلها إلى أرقام؟
نتم عبر طرق تمثيل النصوص (Vectorization):

One-Hot Encoding: تمثيل كل كلمة بمتجه يحتوي على 1 في مكانها و0 في البقية.

Bag of Words (BoW): عد تكرار الكلمات.

TF-IDF: حساب وزن الكلمة بناءً على أهميتها.

Word Embeddings: مثل Word2Vec أو GloVe (تمثيل دلالي عميق)

صمّم Pipeline لمعالجة النصوص.
Text Cleaning: إزالة الرموز والروابط.

Normalization: توحيد الأحرف (مثل أ، إ، آ -> ا).

Tokenization: تقسيم النص لكلمات.

Stop-words Removal: حذف كلمات التوقف.

Stemming/Lemmatization: إرجاع الكلمات لأصلها

لديك Dataset صغير:
أي نموذج تختار ولماذا؟
Dataset صغيرة: نختار نماذج إحصائية بسيطة مثل Naive Bayes أو SVM؛ لأن النماذج المعقدة ستسبب Overfitting

لديك Dataset كبير:
ما النموذج الأفضل؟
Dataset كبيرة: نختار Deep Learning (مثل LSTM أو Transformers/BERT)؛ لأنها تتعلم أنماطاً أعقد مع زيادة البيانات

كيف تحسن دقة نموذج تصنيف نصوص؟
1-تحسين جودة البيانات (Data Augmentation).
2-تجربة تمثيل أفضل للكلمات (مثلاً الانتقال من BoW إلى BERT).
3-ضبط المعاملات الفائقة (Hyperparameter Tuning).
4-استخدام الـ Ensemble Learning (دمج عدة نماذج)

كيف تتعامل مع النصوص العربية؟
تتطلب معالجة خاصة تسمى Arabic Morphological Analysis:
إزالة التشكيل (Tashkeel removal).
توحيد الهمزات والتاء المربوطة.
استخدام أدوات متخصصة مثل CamelTools أو NLTK مع مكتبة Farasa.

صمّم نظام Sentiment Analysis.
1-جمع البيانات: نصوص مصنفة (إيجابي/سلبي).
2-المعالجة: تنظيف النص وتقطيعه.
3-استخراج الميزات: تحويل النص لمتجهات (مثلاً باستخدام TF-IDF).
4-التصنيف: استخدام خوارزمية مثل Logistic Regression.
ا5-لتقييم: حساب الـ Accuracy و F1-score

لديك مشكلة Overfitting:
اقترح 3 حلول

حلول مشكلة الـ Overfitting (3 حلول)
Regularization: مثل (L1/L2) لتقليل تعقيد النموذج.
Dropout: حذف عشوائي لبعض العصبونات أثناء التدريب (في الشبكات العصبية).
Early Stopping: إيقاف التدريب عندما تبدأ الدقة على بيانات التحقق (Validation) بالانخفاض.

قارن بين:
Logistic Regression و Naive Bayes

وجه المقارنة	Naive Bayes	Logistic Regression
النوع	Generative Model	Discriminative Model
السرعة	سريع جداً	أبطأ قليلاً
الافتراض	يفترض استقلالية الكلمات تماماً	لا يفترض الاستقلالية (أكثر مرونة)
الاستخدام	فعال مع النصوص الصغيرة والبريد السبام	أفضل مع البيانات الكبيرة والعلاقات المعقدة

لديك نصوص غير نظيفة:
كيف تنظفها؟
إزالة وسوم HTML والروابط (URLs).
إزالة علامات الترقيم والأرقام غير الضرورية.
إزالة الرموز التعبيرية (Emojis) أو تحويلها لنصوص.
إزالة المسافات الزائدة.

صمّم مشروع NLP كامل (من البداية للنهاية)

Problem Definition: تحديد الهدف (مثلاً تصنيف أخبار).

Data Collection: جمع البيانات (Scraping أو Dataset جاهزة).

EDA: استكشاف البيانات وفهم توزيع الكلمات.

Preprocessing: تنظيف ومعالجة النص (Pipeline).

Feature Engineering: تحويل النص لأرقام.

Modeling: بناء وتدريب النموذج.

Evaluation: اختبار النموذج على بيانات لم يراها.

Deployment: وضع النموذج في تطبيق أو واجهة برمجية (API)

ما هو Byte Pair Encoding (BPE)؟ (ب)
أ) خوارزمية ضغط نصوص
ب) طريقة Tokenization
ج) نموذج لغة
د) خوارزمية تصنيف
Subword Tokenization تستخدم لـ:(ب)
أ) حذف الكلمات
ب) التعامل مع الكلمات النادرة
ج) ترجمة النص
د) ضغط البيانات
ما هو n-gram؟(ب)
أ) نموذج عميق

ب) تسلسل من n كلمات
ج) خوارزمية
د) قاعدة بيانات
Bigram يعني:(ب)
أ) كلمة واحدة
ب) كلمتين
ج) ثلاث كلمات
د) أربع كلمات
Trigram يعني:(ب)
أ) كلمتين
ب) ثلاث كلمات
ج) أربع كلمات
د) خمس كلمات
Perplexity تستخدم لـ:(أ)
أ) قياس جودة النموذج اللغوي
ب) ضغط النص
ج) حذف الكلمات
د) تصنيف الصور
BLEU Score يستخدم في:(ب)
أ) تصنيف النص
ب) الترجمة الآلية
ج) تحليل المشاعر
د) clustering
ROUGE يستخدم في:(ب)
أ) الترجمة
ب) التلخيص
ج) التصنيف
د) التعلم العميق
Seq2Seq Model يستخدم في:(ب)
أ) التصنيف
ب) الترجمة
ج) clustering
د) PCA
Encoder يقوم بـ:(ب)
أ) توليد النص
ب) تمثيل الإدخال
ج) حذف الكلمات
د) ضغط الصور
Decoder يقوم بـ:(ب)
أ) تحليل الصور
ب) توليد النص
ج) حذف الكلمات
د) تصنيف البيانات
Masked Language Model:(أ)
أ) يتوقع الكلمة المحذوفة
ب) يترجم النص
ج) يصنف النص
د) يضغط البيانات
Autoregressive Model:(ب)
أ) يتوقع كل الكلمات دفعة واحدة
ب) يتوقع الكلمة التالية
ج) لا يستخدم سياق
د) نموذج ثابت
Transformer يتكون من:(ج)

أ) Encoder فقط
ب) Decoder فقط
ج) Encoder و Decoder
د) CNN
(ب):Self-Attention
أ) يعتمد على الصور
ب) يربط الكلمات ببعضها
ج) يحذف الكلمات
د) يضغط النص
Positional Encoding يستخدم لـ:(ب)
أ) حذف الترتيب
ب) تمثيل ترتيب الكلمات
ج) ضغط النص
د) حذف الكلمات
Fine-tuning يعني:(ب)
أ) تدريب من الصفر
ب) تحسين نموذج جاهز
ج) حذف البيانات
د) ضغط النموذج
(ب):Transfer Learning
أ) تدريب جديد
ب) نقل المعرفة
ج) حذف البيانات
د) تصنيف الصور
(ب):Zero-shot Learning
أ) تدريب كامل
ب) بدون تدريب مباشر
ج) تعلم عميق
د) clustering
(ج):Few-shot Learning
أ) بيانات كثيرة
ب) بيانات قليلة
ج) بدون بيانات
د) ضغط البيانات

✍ القسم الخامس: أسئلة نظرية متقدمة (15 سؤال)
ا اشرح Subword Tokenization ولماذا هي مهمة.
Subword Tokenization هي طريقة تقوم بتقسيم الكلمات النادرة إلى وحدات أصغر متكررة. مثال: 'الذكاء' -> ['ال', 'ذكاء']

أهميتها:
- تحل مشكلة الكلمات خارج المفردات (Out-of-Vocabulary)
- تقلل حجم المفردات بشكل كبير
- تساعد النماذج على فهم البنى الداخلية للكلمات
- تتعامل مع الكلمات الجديدة والمشتقات

أمثلة: BPE، WordPiece، Unigram
2. ما الفرق بين Autoregressive Models و Masked Language Models؟
▸ Autoregressive Models (مثل GPT):
- تتوقع الكلمة التالية بناءً على الكلمات السابقة فقط
- اتجاه واحد (من اليسار إلى اليمين)
- تستخدم في مهام التوليد (كتابة النصوص، الترجمة)
- مثال: GPT، LLaMA

▸ Masked Language Models (مثل BERT):

- تخفي نسبة من الكلمات وتتوقعها بناءً على السياق المحيط
- اتجاهين (يسار ويمين)
- تستخدم في مهام الفهم (التصنيف، NER)
- مثال: BERT، RoBERTa

3. اشرح مفهوم Perplexity وكيف يتم استخدامه.

Perplexity هو مقياس لتقييم جودة نماذج اللغة.

- المعنى: يقيس مدى حيرة النموذج عند رؤية بيانات جديدة.
- التفسير: كلما كانت القيمة أقل، كان النموذج أفضل في توقع البيانات.

- مثال:
  - نموذج جيد: Perplexity = 20
  - نموذج ضعيف: Perplexity = 200

4. ما الفرق بين BLEU و ROUGE بالتفصيل؟

- BLEU (Bilingual Evaluation Understudy):
  - يستخدم في تقييم الترجمة الآلية
  - يركز على الدقة (Precision)
  - يقيس عدد n-grams في النص المنتج التي تظهر في النص المرجعي

- ROUGE (Recall-Oriented Understudy):
  - يستخدم في تقييم التلخيص
  - يركز على الاستدعاء (Recall)
  - يقيس عدد n-grams في النص المرجعي التي تظهر في النص المنتج

5. اشرح بنية Transformer بالتفصيل.

- Encoder (الجهة اليسرى):
  - يتكون من N طبقات متطابقة
  - كل طبقة تحتوي على:
    - Multi-Head Self-Attention
    - Feed-Forward Network
    - Add & Norm

- Decoder (الجهة اليمنى):
  - يتكون من N طبقات متطابقة
  - كل طبقة تحتوي على:
    - Masked Multi-Head Self-Attention
    - Cross-Attention
    - Feed-Forward Network
    - Add & Norm

6. ما هو Self-Attention وكيف يعمل؟

Self-Attention هي آلية تربط كل كلمة بباقي الكلمات في الجملة لحساب الأهمية النسبية.

- طريقة العمل:
  1. تحويل كل كلمة إلى 3 متجهات: Query (Q)، Key (K)، Value (V)
  2. حساب درجة الانتباه: Q × K^T
  3. تطبيق Softmax للحصول على الأوزان
  4. ضرب الأوزان في V للحصول على الناتج

7. ما هي Positional Encoding ولماذا نحتاجها؟

Positional Encoding هي متجهات تضاف إلى Embeddings الكلمات لتزويد النموذج بمعلومات عن موقع الكلمة.

- لماذا نحتاجها؟
  - لأن Self-Attention لا تحتوي على مفهوم الترتيب
  - بدونها، الجملة 'أكل الولد التفاحة' و 'أكل التفاحة الولد' ستكونان متماثلتين

8. اشرح الفرق بين Encoder و Decoder في Transformer.

- Encoder:

- يقرأ النص المدخل بالكامل (ثنائي الاتجاه)
- ينتج تمثيلاً سياقياً غنياً
- يستخدم في مهام الفهم (BERT)

- Decoder:
  - يولد النص كلمة بكلمة (أحادي الاتجاه)
  - يستخدم Masked Self-Attention
  - يستخدم في مهام التوليد (GPT)

9. ما هو Fine-tuning ولماذا هو مهم؟

Fine-tuning هو عملية أخذ نموذج مدرب مسبقاً ومواصلة تدريبه على مهمة محددة.

- أهميته:
  - يوفر وقتاً وتكلفة التدريب
  - يحقق أداءً عالياً مع بيانات قليلة
  - ينقل المعرفة اللغوية العامة لمهام محددة

10. ما هو Transfer Learning في NLP؟

Transfer Learning هو استخدام المعرفة من نموذج مدرب على مهمة ما لحل مهمة أخرى.

- مراحل Transfer Learning:
  1. Pre-training: تدريب على بيانات ضخمة
  2. Fine-tuning: تكييف على مهمة محددة

11. ما هو Zero-shot Learning مع مثال؟

Zero-shot Learning هي قدرة النموذج على أداء مهمة لم يتدرب عليها مباشرة.

- مثال:
  النموذج لم يتدرب على تصنيف النصوص الطبية.
  التعليم: 'صنف النص إلى: عرض مرضي أو موعد'
  النص: 'أعاني من صداع'
  النتيجة: عرض مرضي

12. ما الفرق بين GPT و BERT؟

- GPT:
  - الهندسة: Decoder-only
  - الاتجاه: أحادي الاتجاه
  - المهام: التوليد (الكتابة، الترجمة)

- BERT:
  - الهندسة: Encoder-only
  - الاتجاه: ثنائي الاتجاه
  - المهام: الفهم (التصنيف، NER)

13. اشرح Seq2Seq Model مع مثال.

Seq2Seq هو نموذج يتكون من Encoder و Decoder لتحويل تسلسل إلى تسلسل.

- مثال: الترجمة الآلية
  الإدخال: 'I love you'
  Encoder: يحولها إلى متجه
  Decoder: يولد 'أنا' ← 'أحب' ← 'ك'

14. ما هي التحديات في بناء Chatbot؟

1. فهم النية: تحديد ما يريده المستخدم
2. إدارة الحوار: الحفاظ على سياق المحادثة
3. الاتساق: عدم التناقض في الإجابات
4. الشخصية: منح الروبوت شخصية ثابتة
5. التعامل مع الحالات غير المتوقعة
6. اللغة الطبيعية: التعامل مع العامية
7. تعدد اللغات

15. كيف تقيم نموذج NLP؟ (metrics)

- التصنيف: Accuracy, Precision, Recall, F1-Score
- الترجمة: BLEU, METEOR
- التلخيص: ROUGE
- نماذج اللغة: Perplexity
- الإجابة عن الأسئلة: Exact Match, F1

القسم السادس: أسئلة عملية / تصميم أنظمة (15 سؤال)

1. لديك نص طويل: كيف تقوم بتلخيصه باستخدام NLP؟
طريقتان: Extractive (TextRank, BERTSUM) و Abstractive (T5, BART).
2. صمّم نظام ترجمة آلية بسيط.
استخدام HuggingFace transformers مع نموذج مثل Helsinki-NLP/opus-mt-en-ar.
3. لديك بيانات متعددة اللغات: كيف تتعامل معها؟
استخدام mBERT أو XLM-Roberta، أو اكتشاف اللغة وتوجيهها لنماذج متخصصة.
4. كيف تبني Chatbot ذكي؟
Retrieval-based (FAISS + Sentence Transformers) أو Generative (GPT fine-tuning).
5. لديك مشكلة Ambiguity في النص: كيف تعالجها؟
استخدام BERT للسياق، Coreference Resolution، و Word Sense Disambiguation.
6. كيف تتعامل مع Out-of-Vocabulary words؟
استخدام Subword Tokenization (BPE, WordPiece) أو FastText.
7. لديك Dataset غير متوازن: كيف تعالجه؟
SMOTE, class weights, focal loss, أو جمع بيانات إضافية.
8. كيف تبني نظام NER باستخدام Deep Learning؟
BERT + طبقة تصنيف + CRF، مع Fine-tuning على بيانات NER.
9. كيف تستخدم Transformer في مشروعك؟
اختيار نموذج مناسب، Fine-tuning، تصدير ONNX، وإنشاء API.
10. كيف تختار بين BERT و GPT حسب المهمة؟
BERT للفهم (تصنيف، NER)، GPT للتوليد (كتابة، ترجمة).
11. لديك نصوص noisy: كيف تنظفها؟ (advanced level)
إزالة HTML، تطبيع عربي، إزالة تشكيل، تصحيح إملائي باستخدام Farasa.
12. كيف تحسن سرعة inference لنموذج NLP؟
Quantization, pruning, distillation, ONNX, TensorRT.
13. صمّم نظام Question Answering.
Extractive QA (BERT) أو Generative QA (T5) مع Fine-tuning.
14. كيف تبني نظام Text Summarization؟
استخدام PEGASUS أو BART مع Fine-tuning على بيانات التلخيص.
15. صمّم نظام NLP متكامل لشركة (مثلاً بنك أو خدمة عملاء)
تحليل المشاعر، تصنيف الشكاوى، NER، Chatbot لاستخراج المعلومات، مع API ونظام مراقبة.

نقل المعرفة من نموذج مدرب على بيانات ضخمة لمهام أخرى.